

GUIA DE APRENDIZAJE N 1: DATOS, INFORMACIÓN, TOMA DE DECISIONES, FUENTES Y FORMATOS

Nataly Estefany Suarez Velandia

Eileen Carolina Novoa Beltran

Cristian Andres Becerra Reyes

Giann Sebastian Romero Gonzalez

CENTRO DE MATERIALES Y ENSAYOS

FICHA TECNICA:
3602991

PROCESAMIENTO DE DATOS PARA MODELOS DE INTELIGENCIA ARTIFICIAL

DOCENTE:

NATHALIA MARTINEZ VARGAS

2.1.1 Actividades de Desarrollo

1. Documentar de manera concisa las diferencias estructurales entre un archivo de texto plano (CSV), un formato de hoja de cálculo heredado (XLS) y uno moderno (XLSX), haciendo ´énfasis en sus l´ımites de almacenamiento (filas y columnas) e identificando en qué punto exacto fall´o la integridad de los datos en el caso expuesto.

-CSV (Comma Separated Values)

Es un archivo de texto que guarda información separada por comas o dependiendo de la configuración, otros separadores como punto y coma.

Se utiliza para guardar e intercambiar datos de manera sencilla. No conserva colores, fórmulas ni diseños de una hoja de cálculo sin límite fijo establecido por el formato.

XLS (Excel Spreadsheet)

Es un formato antiguo de Microsoft Excel, utilizado para guardar hojas de cálculo.

Permite almacenar datos, fórmulas, colores, tablas y formatos. Su límite es de 65.536 filas y 256 columnas por hoja.

-XLSX (Excel Open XML)

Es el formato moderno de Excel, que reemplazó al XLS como formato predeterminado.

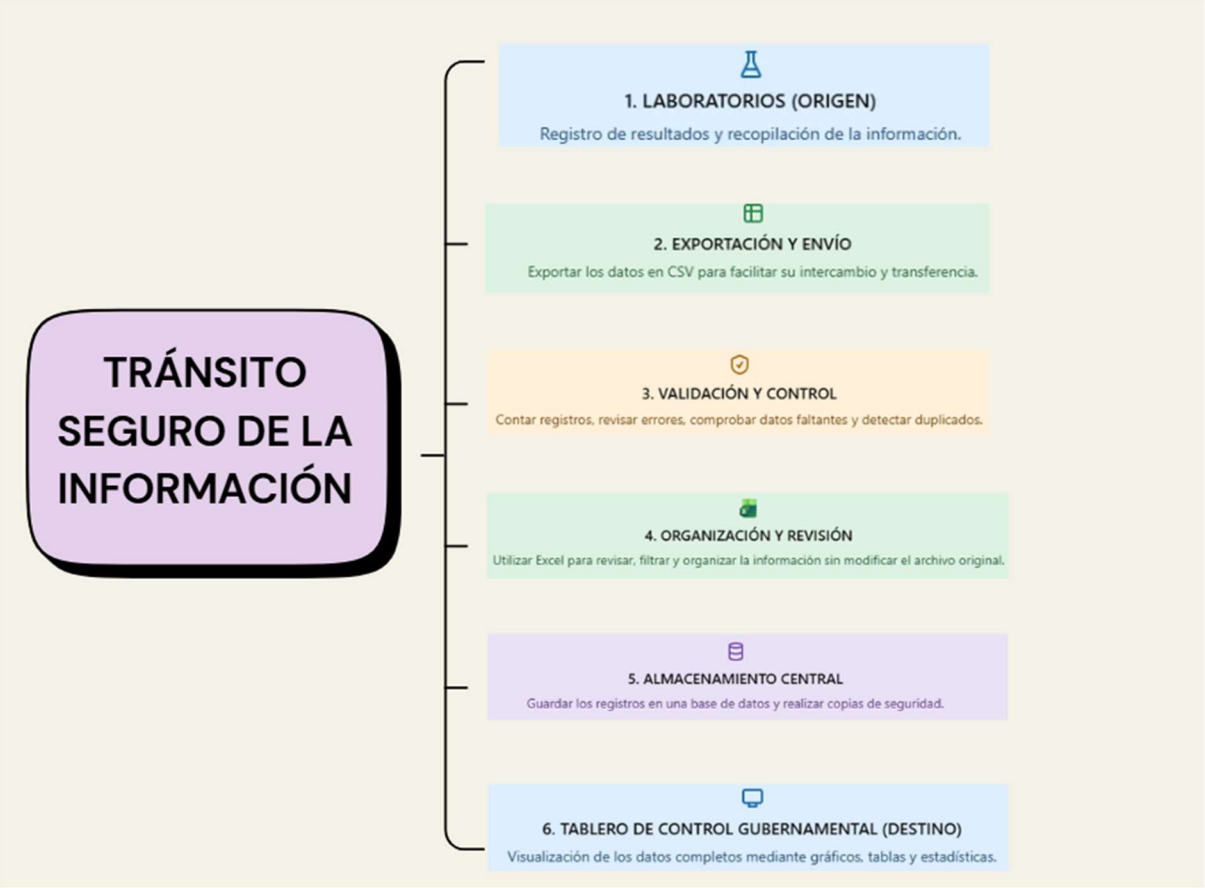
Permite guardar datos, fórmulas, gráficos, colores y varias hojas de cálculo. Tiene un límite de 1.048.576 filas y 16.384 columnas por hoja

¿En qué punto exacto falló la integridad de los datos?

El error durante la transferencia automática de los resultados de laboratorio. Los laboratorios enviaban los datos en archivos CSV, pero el sistema los importaba a plantillas de Excel en formato XLS, El problema surgió cuando el número de registros superó el límite de 65.536 filas que admite el formato XLS. El sistema no emitió ninguna alerta, por lo que los registros adicionales no se incluyeron.Como resultado, 15.841 resultados positivos no se registraron a tiempo en las estadísticas oficiales y no se enviaron al sistema de rastreo de contactos. Esto también significó que más de 50.000 contactos cercanos no fueron localizados a tiempo.

El error de integridad de los datos ocurrió al usar un formato de almacenamiento que no podía manejar toda la información. Este problema se podría haber evitado usando XLSX o manteniendo un procesamiento adecuado en CSV. También sería importante implementar controles para detectar errores y registros perdidos.

2. Elaborar un esquema conceptual que ilustre cómo debió ser el tránsito seguro de la información desde los laboratorios (origen) hasta el tablero de control gubernamental (destino). Se debe justificar qué formatos (CSV o XLSX) debieron emplearse en cada etapa para garantizar la preservación de los casi 16.000 registros perdidos.



- Para evitar que se pierda información, es importante utilizar correctamente los formatos CSV y XLSM durante el proceso. Formato CSV se utilizará desde laboratorios para enviar datos, ya que permite guardar y compartir información de manera sencilla. Después, formato XLSX (Excel) se utilizaría para revisar y organizar datos, ya que permite usar filtros y fórmulas para encontrar posibles errores. También sería importante guardar copias de archivos originales y revisar qué cantidad de datos enviados sea la

misma que cantidad de datos recibidos.De esta manera, se conservaría mejor información y evitaría que se pierdan registros durante el proceso hasta llegar al tablero de control del Gobierno.

3. Redactar una conclusión analıtica sobre la relación directa entre el conocimiento técnico del analista de datos y la responsabilidad ética en la toma de decisiones a nivel gerencial o gubernamental.

-El conocimiento técnico de un analista de datos es muy importante porque le permite organizar, revisar e interpretar correctamente la información. Sin embargo, un analista de datos también debe tener responsabilidad ética, porque los datos que analiza pueden influir en decisiones que afectan a muchas personas. Por eso, un analista de datos debe trabajar con información verdadera, evitar errores, no modificar los resultados y proteger los datos que maneja. En conclusión, un buen analista de datos no solo debe saber utilizar las herramientas tecnológicas, sino también ser responsable y honesto, porque sus análisis pueden ayudar a tomar mejores decisiones en las empresas y en el Gobierno.

2.2 Actividades de contextualización e identificación de conocimiento

Bitácora de exploración y clasificación de datos	
2.2.1 Enunciado del eje temático y justificación	Para el eje temático se decidió junto con el grupo de trabajo, trabajar datasets relacionados con la educación. Esto se realiza con el objetivo principal de comprender distintos aspectos sociodemográficos como la edad, el sexo y el tipo de carreras que los estudiantes escogen.

2.2.2 Párrafo argumentativo de clasificación y justificación	Para los 3 archivos utilizados en esta práctica se utilizan bases de datos de extracción de tipo secundaria, esto debido a que toda la información obtenida ya fue recopilada por sus respectivos autores a través de encuestas, organizaciones y academias.
2.2.3 Listado de conjuntos de datos	1. Dataset N°1: ● Nombre: Student Dropout Analysis for School Education ● Portal: Kaggle ● Enlace: Student Dropout Analysis for School Education 2. Dataset N°2: ● Nombre: Covid19 and Education ● Portal: Kaggle ● Enlace: Covid19 and Education 3. Dataset N°3: ● Nombre: Education ● Portal: Kaggle ● Enlace: Education

2.2.4 Tabla estructurada extraída de los datasets seleccionados

Tabla 1

Análisis de deserción escolar en la educación escolar

Dataset	Variables	Categoria	Subcategoria
Student dropout analysis for school education	Marital status	Cualitativa	Nominal
Student dropout analysis for school education	Application mode	Cualitativa	Nominal
Student dropout analysis for school education	Application order	Cuantitativa	Discreta

Student dropout analysis for school education	Course	Cualitativa	Ordinal
Student dropout analysis for school education	Daytime/evening attendance	Cualitativa	Ordinal
Student dropout analysis for school education	Previous qualification	Cualitativa	Nominal
Student dropout analysis for school education	Nationality	Cualitativa	Nominal
Student dropout analysis for school education	Mother's qualification	Cualitativa	Nominal
Student dropout analysis for school education	Father's qualification	Cualitativa	Nominal
Student dropout analysis for school education	Mother's occupation	Cualitativa	Nominal

Tabla 2

El Covid 19 y la educación

Dataset	Variables	Categoria	Subcategoria
Covid19 and education	Country code	Cualitativa	Nominal

Covid19 and education	Country name	Cualitativa	Nominal
Covid19 and education	Dt extraction	Cuantitativa	Discreta
Covid19 and education	If closed due to covid19 when	Cuantitativa	Discreta
Covid19 and education	Income level	Cualitativa	Ordinal
Covid19 and education	Region name	Cualitativa	Nominal
Covid19 and education	School status	Cualitativa	Ordinal
Covid19 and education	Year pre	Cuantitativa	Discreta
Covid19 and education	Year prm	Cuantitativa	Discreta
Covid19 and education	Year sec	Cuantitativa	Discreta

Tabla 3

La educación, PIB y desempleo

Dataset	Variables	Categoria	Subcategoria
Education	Country	Cualitativa	Nominal
Education	Date	Cuantitativa	Discreta
Education	GNP	Cuantitativa	Continua

Education	Population	Cuantitativa	Discreta
Education	Edu prime	Cuantitativa	Continua
Education	Edu second	Cuantitativa	Continua
Education	Edu post second	Cuantitativa	Continua
Education	Edu lower second	Cuantitativa	continua
Education	Unemp	Cuantitativa	Continua
Education	C codes	Cualitativa	Nominal

2.3. Actividades de Apropiación del Conocimiento

Con base en la temática concertada previamente, cada equipo selecciona y descarga dos (2) datasets reales (obligatoriamente uno en formato CSV y otro en formato XLSX) alojados en los portales explorados. A continuación, ejecutará una auditoría técnica rigurosa sobre ambos archivos para descubrir y documentar por lo menos seis (6) inconsistencias en los datos. Para la explicación de los problemas encontrados use la siguiente estructura:

- ¿Qué o cuál es el problema?
- ¿Cómo se ha detectado?
- ¿Por qué cree que se trata de un problema?
- ¿Un ejemplo completo extraído del propio dataset?

Data set educacion: https://www.kaggle.com/code/ammon1/education/input

¿Qué o cuál es el problema?

Se identificaron registros incoherentes de la columna de los países que contienen categorías de agrupaciones como IBRD ONLY, IDA ONLY e IDA TOTAL, las cuales no representan países individuales.

¿Cómo se ha detectado?

En la revisión de las categorías disponibles de la columna de países en Excel, se encontraron nombres de países mezclados con categorías que representan agrupaciones que no eran paises.

¿Por qué cree que se trata de un problema?

La columna debería mostrar países por lo cual se encontró una agrupación diferente . La mezcla de países con categorías agrupadas puede generar confusiones y afectar los análisis estadísticos, como el conteo de países y las comparaciones entre ellos.

1 Imagen del error



2 Data set (Educacion)

https://www.kaggle.com/code/ammon1/education/input

¿Qué o cuál es el problema?

Se identificaron registros sin información en la columna GNP (Producto Nacional Bruto).

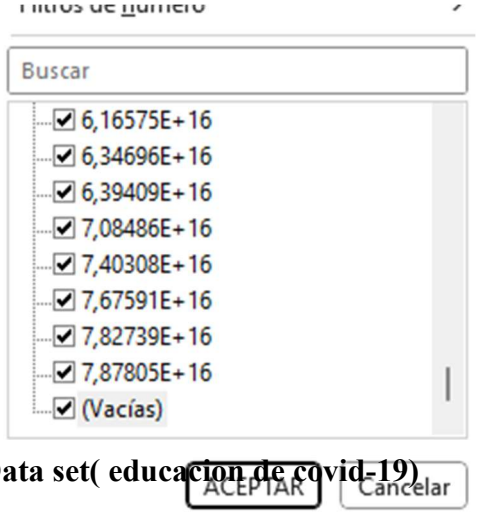
¿Cómo se ha detectado?

Mediante el uso del filtro de Excel, donde se encontró la categoría (Vacías).

¿Por qué cree que se trata de un problema?

Porque la ausencia de información económica puede complicar el análisis y la comparación entre los países.

2 Imagen del error



3Data set(educacion de covid-19)

https://www.kaggle.com/code/mpwolke/covid19-and-education/input

¿Qué o cuál es el problema?

Se identificaron registro que contiene un asterisco (*) en lugar del nombre de un país en la columna correspondiente.

¿Cómo se ha detectado?

la revisión de los registros de la columna País utilizando los filtros de Excel, donde se encontró el símbolo como un valordiferente .

¿Por qué cree que se trata de un problema?

Porque el asterisco no permite identificar el país al que corresponde el registro, lo que puede dificultar la clasificación, organización y análisis de la información.

3 Imagen del error



2.4 Actividades de transferencia de conocimiento

Diccionario de Datos del Dataset de COVID-19 y Educación

En este trabajo organizamos y explicamos a fondo toda la estructura del archivo '(education_COVID-19 eileen .csv)'. Revisamos columna por columna para que quede muy claro qué significa cada dato, qué tipo de información guarda y los detalles que encontramos de cuando las escuelas cerraron por la pandemia.

Tabla 4

Aspectos basicos del archivo

Nombre del archivo	education_COVID-19 eileen .csv
¿De qué trata?	De cómo afectó la pandemia del COVID-19 a las escuelas en varios países y cuántos estudiantes había matriculados (datos de la UNESCO y Banco Mundial).
Total de filas (países/registros)	201 filas
Total de columnas (variables)	18 columnas
Formato de texto	UTF-8
Separador de datos	Comas (,)

Tabla 5

Diccionario de datos

Country Code	Código del País	VARCHAR (3)	Sí	PK	Es el código de 3 letras que identifica al país (como una abreviatura única).	'ERI'
Country Name	Nombre del País	VARCHAR (100)	Sí	N/A	El nombre tal cual del país.	'Eritrea'
Dt Extraction	Fecha de extracción	DATETIME	No	N/A	El día y la hora exacta en que sacaron estos datos de la base original.	'07-07-2020 03:28'

If Closed Due To COVID19 When	Fecha de cierre por COVID	VARCHAR (30)	Sí	N/A	La fecha en la que cerraron los colegios por la cuarentena.	'01 March 2020'
Income Level	Nivel de ingresos	VARCHAR (30)	Sí	N/A	Qué tan rico o pobre es el país según el Banco Mundial (Low, Middle, High income).	'Low income'
Region Name	Región / Continente	VARCHAR (50)	Sí	N/A	La zona del mundo donde queda el país.	'Sub-Saharan Africa'
School Status	Estado de las escuelas	VARCHAR (50)	No	N/A	Si los colegios estaban cerrados ('Closed'), abiertos ('Open') o a medias.	'Closed'
Year Pre	Año datos Preescolar	INTEGER	Sí	N/A	De qué año son los datos de los niños de preescolar.	2018
Year Prm	Año datos Primaria	INTEGER	Sí	N/A	De qué año son los datos de los estudiantes de primaria.	2018

Year Sec	Año datos Secundaria	INTEGER	Sí	N/A	De qué año son los datos de los chicos de bachillerato/ secundaria.	2018
Year Ter	Año datos Universidad	INTEGER	Sí	N/A	De qué año son los datos de la educación superior o universidad.	2016
Latitude	Latitud	DECIMAL(8,4)	Sí	N/A	La ubicación en el mapa (qué tan al norte o al sur está).	15.9820
Longitude	Longitud	DECIMAL(8,4)	Sí	N/A	La ubicación en el mapa (qué tan al este u oeste está).	38.0200
Enrollment	Matrícula Total	VARCHAR (20)	Sí	N/A	El total de estudiantes que había inscritos en general.	'6,67,452'
Se Pre Enrl	Matrícula Preescolar	VARCHAR (20)	Sí	N/A	Cantidad de niños inscritos en preescolar.	'47,047'
Se Prm Enrl	Matrícula Primaria	VARCHAR (20)	Sí	N/A	Cantidad de estudiantes en primaria.	'3,49,753'
Se Sec Enrl	Matrícula Secundaria	VARCHAR (20)	Sí	N/A	Cantidad de estudiantes en secundaria.	'2,60,421'

oSe Ter Enrl	Matrícula Universidad	VARCHAR (20)	Sí	N/A	Cantidad de estudiantes en la universidad.	'10,231'

Observacion de los datos

- **Las comas en los números de estudiantes:** En las columnas de matrícula (Enrollment, Se Pre Enrl, etc.) los números vienen escritos como texto con comas raras (ejemplo: '6,67,452' al estilo de la India) Toca arreglarlos quitando las comas para que Excel o el programa los lea bien como números enteros.
- **Los años vienen con decimales:** Los años aparecen como '2018.0' en lugar de '2018'. Hay que quitarles el punto y el cero para que queden normales.
- **Datos que faltan (Nulos):** Hay 2 países que no tienen código, 4 que no dicen su región o nivel de ingresos y 18 a los que les falta la fecha exacta de cierre. Hay que decidir si los borramos o los completamos.

2.4.1 Diccionario de datos

Tabla de origen	Campo / Elemento	Descripción	Tipo	Formato / dominio / valor	Fuente	Observaciones	Clasificación estadística
Datos del resultado	id_resultado	Identificador del resultado de cada prueba procesada	Texto / numérico	Único por prueba	Laboratorios comerciales	Inferido	Cualitativa nominal
Datos del resultado	resultado_prueba	Resultado de la prueba de COVID-19	Categórico	Positivo / Negativo	Laboratorios comerciales	El incidente afectó a los positivos	Cualitativa nominal (dicotómica)
Datos del resultado	fecha_resultado	Fecha en que el laboratorio emitió el resultado	Fecha	AAAA-MM-DD	Laboratorios comerciales	Se usa para el conteo diario. Inferido	Cuantitativa (escala de intervalo)
Datos del resultado	laboratorio_origen	Laboratorio que procesó la prueba	Texto	Nombre o código	Laboratorios comerciales	Inferido	Cualitativa nominal
Datos del resultado	contactos_estrechos	Personas expuestas a un	Numerico (estimado)	Entero, ≈3 por	Sistema de rastreo	Es un promedio, no	Cuantitativa discreta

		caso positivo, que deben localizarse		caso		un conteo confirmado	
Archivos y formatos	archivo_resultados_diarios	Archivo diario que cada laboratorio envía a PHE	Archivo	.csv (texto plano)	Laboratorios comerciales	Formato original, sin límite de filas	Cualitativa nominal
Archivos y formatos	plantilla_consolidacion	Plantilla donde el proceso automatizado importa los CSV	Archivo	.xls (Excel heredado)	Proceso automatizado de PHE	Causa raíz: formato inadecuado	Cualitativa nominal
Archivos y formatos	limite_filas_xls	Máximo de filas permitido por el formato .xls	Numérico	65,536	Especificación del formato	Se superó rápidamente	Cuantitativa discreta
Archivos y formatos	filas_excedentes	Registros que superan el límite	Numérico	Entero	Calculado	Se truncaron sin alerta de error	Cuantitativa discreta
Indicadores	periodo_afectado	Intervalo con resultados omitidos	Rango de fechas	25-sep-2020 a 2-oct-2020	House of Commons (2020, p. 625)	Periodo de omisión de resultados positivos	Cuantitativa (intervalo de fechas)

Indicadores	positivos_omitidos	Positivos que no entraron en las cifras diarias ni en el rastreo	Numérico	15,841	House of Commons (2020, p. 625)	Cifra exacta	Cuantitativa discreta
Indicadores	casos_diarios_publicados	Casos mostrados en los tableros de control	Numérico	Variable	Dashboards de PHE	Subestimados por el fallo	Cuantitativa discreta
Indicadores	contactos_no_alertados_est	Contactos que pudieron no ser localizados a tiempo	Numérico (estimado)	> 50.000	Halliday et al. (2020)	Estimación, no conteo confirmado	Cuantitativa discreta
Fuentes y sistemas	Laboratorios comerciales	Procesan las pruebas y envían los resultados diarios				Rol: Fuente primaria	Cualitativa nominal
Fuentes y sistemas	Proceso automatizado de PHE	Importa los CSV a plantillas XLS				Rol: Transformación / carga	Cualitativa nominal
Fuentes y sistemas	Sistema central de PHE	Consolida los datos				Rol: Almacenamiento	Cualitativa nominal

Fuentes y sistemas	Tableros de control (dashboards)	Muestran las cifras diarias				Rol: Visualización para decisiones	Cualitativa nominal
Fuentes y sistemas	Sistema de rastreo de contactos	Recibe los positivos para localizar contactos				Rol: Uso operativo	Cualitativa nominal
Reglas	Regla 1	Un archivo .xls admite como máximo 65.536 filas.			Texto base		Cualitativa (texto)
Reglas	Regla 2	El sistema truncaba los datos excedentes sin generar alertas (falla silenciosa).			Kelion (2020)		Cualitativa (texto)
Reglas	Regla 3	Los positivos omitidos no se publicaron ni pasaron al rastreo, pero las personas afectadas sí			House of Commons (2020, p. 625)		Cualitativa (texto)

		recibieron su resultado y la indicación de aislarse en el plazo habitual.					
Reglas	Regla 4	La cifra de 50.000 contactos es una estimación basada en promedios por caso.			Halliday et al. (2020)		Cualitativa (texto)

2.5 Bibliografia

Formato de archivo CSV y ejemplos. (2026, 24 septiembre). IBM. Recuperado 7 de noviembre de 2026, de https://www.ibm.com/docs/es/engineering-lifecycle-management-suite/doors-next/7.2.0?topic=files-csv-file-format-examples

Glosario para desarrolladores de software de gestión. (2025, 12 febrero). Velneo. Recuperado 7 de noviembre de 2026, de https://velneo.com/blog/glosario-desarrolladores-software-gestion/

Bansal, S. (2026, 19 junio). CSV vs XLSX: Key Differences and When to Use Each. *Trump Excel*. https://trumpexcel.com/csv-vs-xlsx/

Mygems. (2026, 7 agosto). *CSV vs XLSX: qué formato usar y cuándo*. Mygems. https://mygems.app/es/guides/csv-vs-xlsx